

DIAGNÓSTICO DE IMÁGENES HISTOLÓGICAS DE PRÓSTATA UTILIZANDO MÉTODOS DE EXPLICABILIDAD EN DEEP LEARNING

PEDRO GALLEGO LÓPEZ

Trabajo Fin de Grado

Doble Grado en Ingeniería Informática y Matemáticas

Tutores

- Francisco Herrera Triguero
- Francisco Luque Sánchez

Granada, a 29 de junio de 2022

FACULTAD DE CIENCIAS Y E.T.S. DE INGENIERÍAS INFORMÁTICA Y TELECOMUNICACIONES

ÍNDICE

- 1. Contexto**
- 2. Objetivos**
- 3. Herramientas**
- 4. Metodología**
- 5. Desarrollo / Resultados**
- 6. Conclusiones y Trabajo Futuro**

CONTEXTO

CONTEXTO

DEEP LEARNING EN VISIÓN POR COMPUTADOR

Modelos de Caja Negra.

Ejemplo: Redes Neuronales Convolucionales.

EXPLICABILIDAD

Supone una barrera para el desarrollo de la Inteligencia Artificial.

Brinda de técnicas para dar transparencia a los modelos de Caja Negra

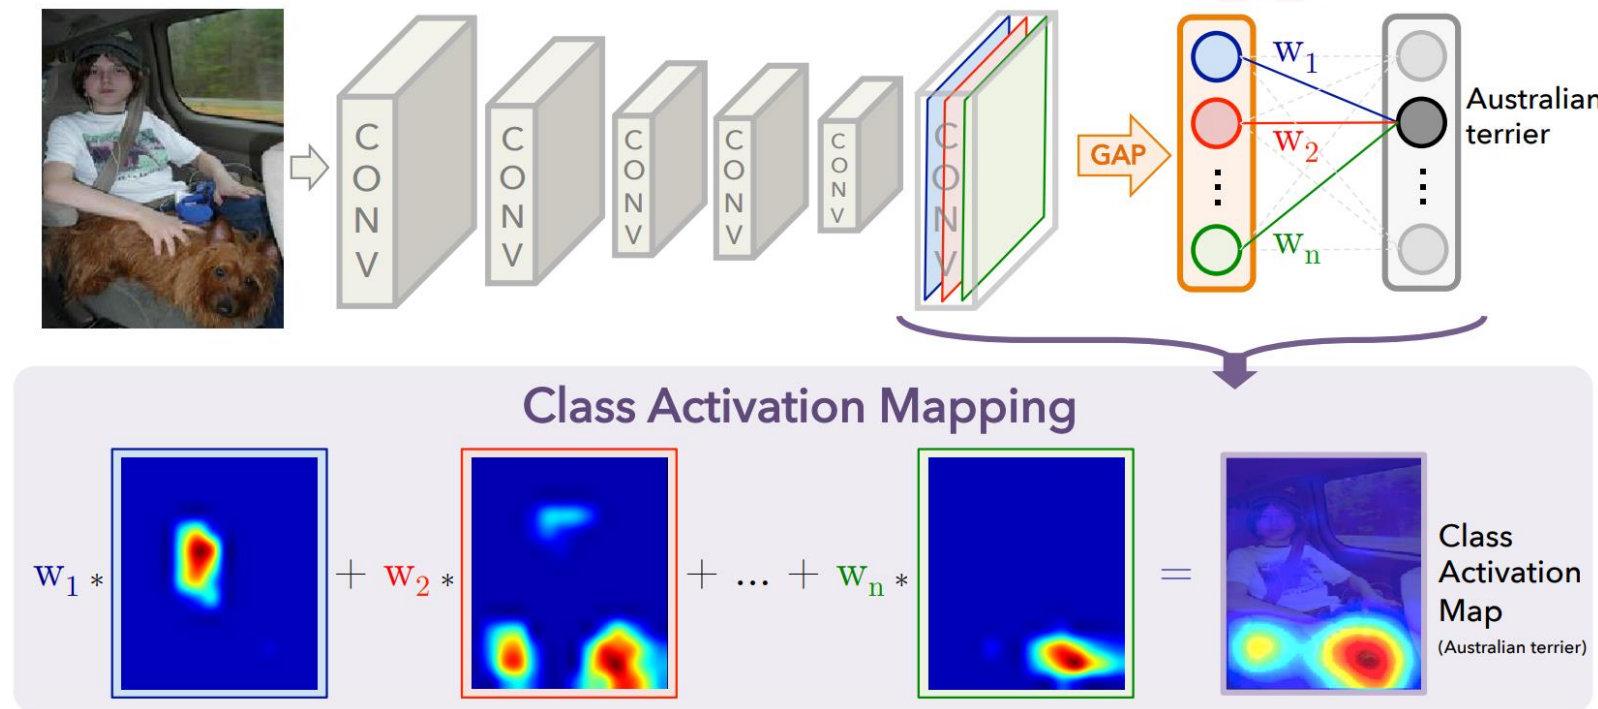
Ejemplo de técnicas:

Class Activation Map (CAM), Grad-CAM, Grad-CAM++, Smooth Grad-CAM++

CONTEXTO – Explicabilidad

CAM – Class Activation Mapping

Idea base: Las unidades convolucionales son detectores de localización no supervisados de objetos.



CONTEXTO – Explicabilidad

1 - CAM

- **PROBLEMA:** Se pierde la información en las capas totalmente conectadas.
- **SOLUCIÓN:** Usar *GlobalAveragePooling* y una sola capa totalmente conectada.

2 – Grad-CAM

- **PROBLEMA:** Restricción de arquitectura.
- **SOLUCIÓN:** Usa Gradientes para calcular los pesos de los mapas de activación.

3 – Grad-CAM++

- **PROBLEMA:** Múltiples apariciones de una clase se eclipsaban unas a otras.
- **SOLUCIÓN:** Ponderación a nivel de píxel para igualar importancia de las apariciones.

4 – Smooth Grad-CAM++

- **PROBLEMA:** sensibles al ruido de las imágenes.
- **SOLUCIÓN:** uso de la técnica de *Smooth Grad* en la aplicación de Grad-CAM++.
Añadir ruido para eliminarlo.

OBJETIVOS

OBJETIVOS

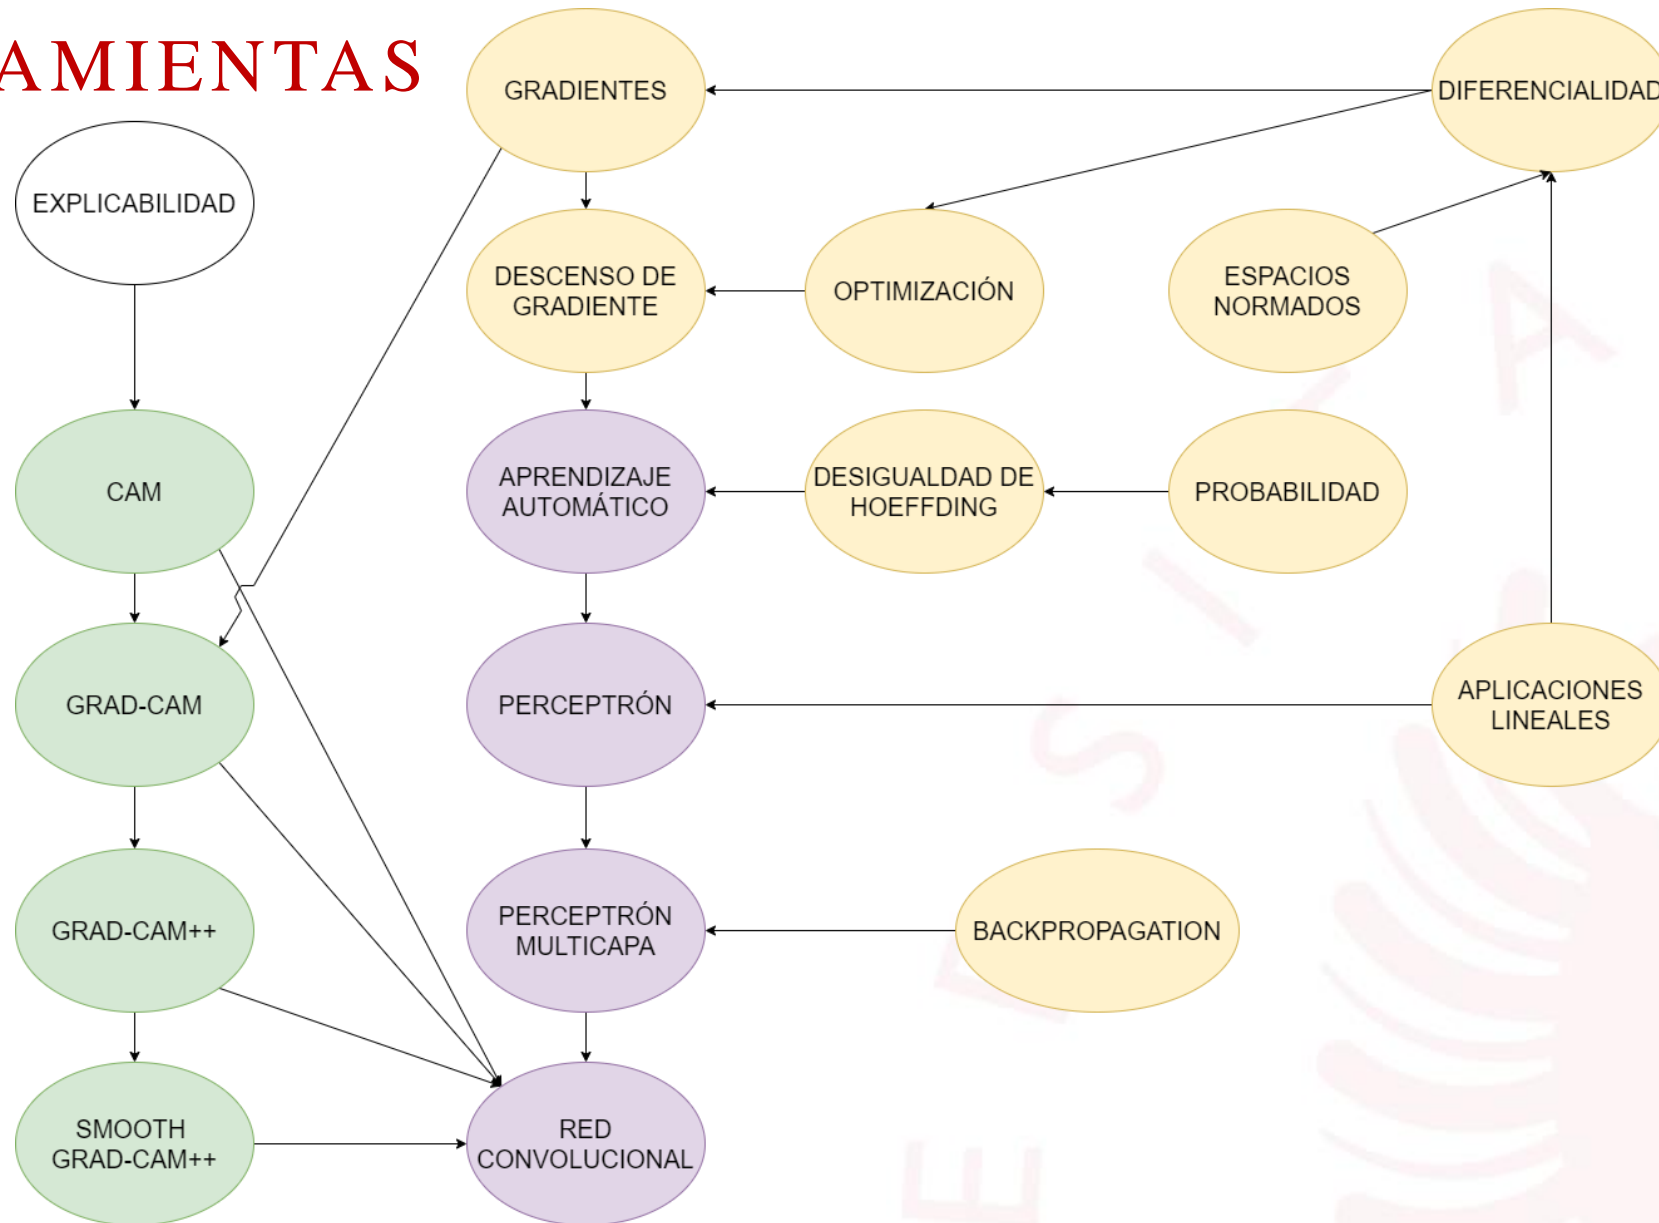
Estudiar los conceptos matemáticos en los que se basa el aprendizaje y las técnicas de explicabilidad

Analizar la capacidad para localizar de los modelos con las técnicas de explicabilidad:

- i. Estudiar las limitaciones de localización de las técnicas.
- ii. Encontrar relación entre la capacidad de clasificación y localización de un modelo.
- iii. Determinar si la mejor técnica y el mejor modelo corresponden con la literatura más avanzada
- iv. Valorar si la mejor técnica y el mejor modelo es una herramienta útil para un experto.

HERRAMIENTAS

HERRAMIENTAS



METODOLOGÍA

METODOLOGÍA

1. Establecer el marco de trabajo del problema:
 - a) Escoger el conjunto de datos.
 - b) Elegir sobre qué redes de la literatura se va a realizar el estudio.
2. Preprocesar los datos.
3. Entrenar y validar los modelos para clasificación.
4. Testear los modelos para clasificación.
5. Testear los modelos y las técnicas para localización.
6. Contraste y análisis de resultados

DESARROLLO Y RESULTADOS

DESARROLLO Y RESULTADOS – Marco de Trabajo

TÉCNICAS DE EXPLICABILIDAD

CAM, GRAD-CAM, GRAD-CAM++,
SMOOTH GRAD-CAM++


MODELOS

VGG 16, RESNET 18,
MOBILENETv2 y EFFICIENTNET B0.

- **cam:** 1 capa totalmente conectada
- **cam_pro:** 3 capas totalmente conectadas


CONJUNTO DE DATOS

SICAPv1: imágenes histológicas de próstata con
etiquetado de máscaras de tejido cancerígeno




DESARROLLO Y RESULTADOS – Marco de Trabajo


**MALA PRECISIÓN
EN EL ETIQUETADO**




**FALLO INTRÍNSECO EN
EL CÁLCULO DE LAS
MÉTRICAS**



DESARROLLO Y RESULTADOS – Preprocesado de Datos



1. Obtener imágenes de 224×224 con solapamiento.
2. Filtro: >25% de tejido de la propia clase
3. Generación del conjunto de validación



DESARROLLO – Testear los Modelos para Clasificación.

MÉTRICAS

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN}$$

$$Recall = \frac{TP}{TP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$F1 - Score = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

DESARROLLO – Testear los Modelos para Localización.

UMBRALIZACIÓN

1. Seleccionar un número finito de umbrales sobre el intervalo [0,1].
2. Testear la localización de la máscara generada para cada umbral.
3. Recoger las métricas del mejor umbral.

MÉTRICAS

$$IoU = \frac{TP}{TP + FP + FN}$$


$$Recall = \frac{TP}{TP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$F1 - Score = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN}$$

DESARROLLO – Testear los Modelos para Localización.

UMBRALIZACIÓN



umbral = 0



umbral = 0.25



umbral = 0.5



umbral = 0.75



umbral = 1

DESARROLLO – Contraste y Análisis de los Resultados

ANÁLISIS DEL MEJOR MODELO

Clasificación

Se hace una comparación global con todas las métricas de clasificación.

Localización

Partiendo de las métricas del mejor umbral para cada modelo, se hará una comparación global de todas las métricas sobre imágenes patológicas, siendo la de mayor peso el Intersection over Union.

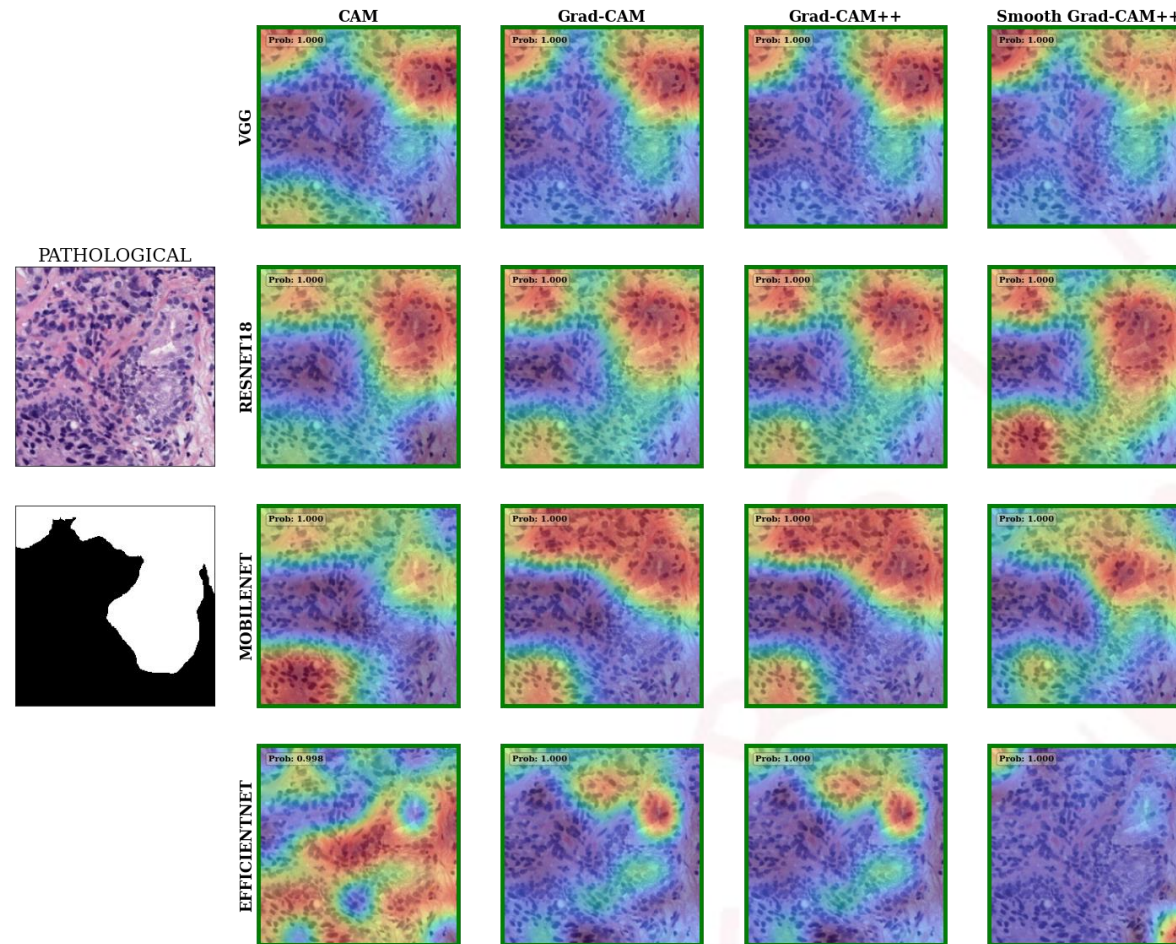
ANÁLISIS DE LA MEJOR TÉCNICA DE EXPLICABILIDAD

Con las mismas estadísticas que en el Análisis de Localización del Mejor Modelo. además de estas estadísticas se valorará la consistencia de la técnica: si mantiene la misma calidad sobre todos los modelos.

ANÁLISIS DEL MEJOR PAR MODELO-TÉCNICA

DESARROLLO – Contraste y Análisis de los Resultados

EJEMPLO DE EXPLICABILIDAD EN UNA IMAGEN



DESARROLLO – Contraste y Análisis de los Resultados

ANÁLISIS DEL MEJOR MODELO - Clasificación

	VGG		RESNET18		MOBILENET		EFFICIENTNET	
	cam	cam_pro	cam	cam_pro	cam	cam_pro	cam	cam_pro
Accuracy	0.9862	0.9912	0.9791	0.9826	0.9813	0.9820	0.9625	0.9621
Recall	0.9792	0.9867	0.9633	0.966	0.9774	0.9714	0.9503	0.9518
Precision	0.9903	0.9939	0.9904	0.9953	0.9813	0.9887	0.9663	0.964
F1-Score	0.98471	0.9903	0.9767	0.9804	0.9793	0.98	0.9582	0.9579

RANKING (Recall)

- | | |
|----------------------|-------------------------|
| 1. VGG cam_pro | 5. RESNET18 cam_pro |
| 2. VGG cam | 6. RESNET18 cam |
| 3. MOBILENET cam | 7. EFFICIENTNET cam_pro |
| 4. MOBILENET cam_pro | 8. EFFICIENTNET cam |

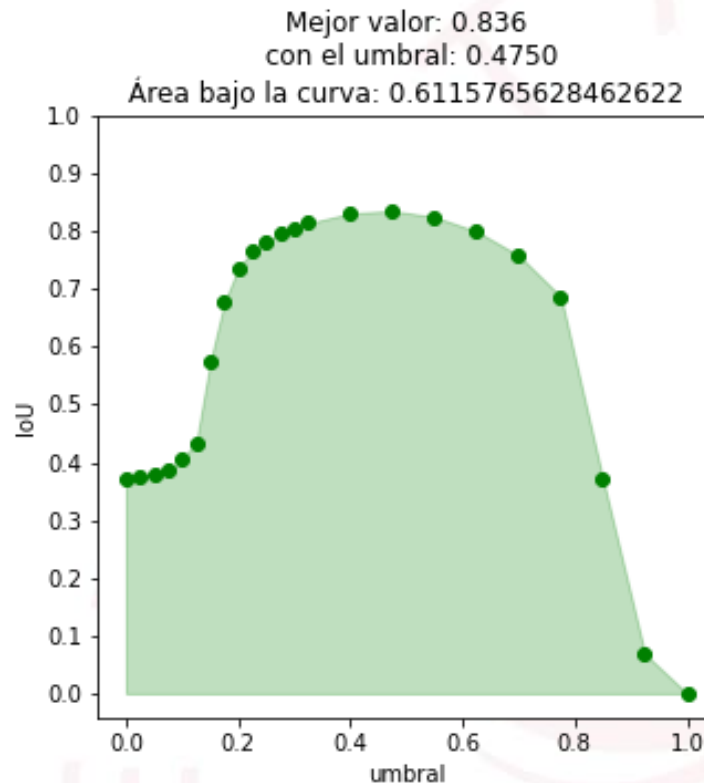
DESARROLLO – Contraste y Análisis de los Resultados

ANÁLISIS DEL MEJOR MODELO - Localización

Pseudo cota superior:

Error intrínseco del problema al redimensionar el mapa de activación

$$IoU_{sup} = 0,836$$




DESARROLLO – Contraste y Análisis de los Resultados

ANÁLISIS DEL MEJOR MODELO - Localización

Sesgo en el conjunto de datos:


Gran cantidad de imágenes donde el 100% de su información es tejido patológico.



Una máscara trivial (que marcase que todo es tejido patológico) tendría muy buenos resultados en las métricas.



Interesa coger imágenes con un porcentaje de tejido patológico bajo.
Elección: <50%



DESARROLLO – Contraste y Análisis de los Resultados

ANÁLISIS DEL MEJOR MODELO - Localización

	VGG				RESNET18				MOBILENET				EFFICIENTNET			
	cam		cam_pro		cam		cam_pro		cam		cam_pro		cam		cam_pro	
	C	GC	GC++	SGC++	C	GC	GC++	SGC++	C	GC	GC++	SGC++	C	GC	GC++	SGC++
Umbral	0.2	0.2	0.2	0.225	0.275	0.3	0.3	0.25	0.25	0.275	0.275	0.275	0.	0.15	0.15	0.15
IoU	0.5837	0.6054	0.6023	0.6093	0.4902	0.5121	0.5121	0.4391	0.528	0.5259	0.5259	0.4732	0.3733	0.5207	0.5207	0.5203
Recall	0.8155	0.8536	0.8587	0.8501	0.7421	0.8189	0.8189	0.8151	0.8003	0.8388	0.8388	0.8208	1.	0.7838	0.7838	0.7788
Precision	0.6838	0.684	0.6747	0.6896	0.6004	0.5760	0.5760	0.4848	0.6205	0.5939	0.5939	0.5387	0.3733	0.6122	0.6122	0.6098
F1-Score	0.7439	0.7594	0.7557	0.7615	0.6638	0.6763	0.6763	0.6175	0.699	0.694	0.694	0.6487	0.5437	0.6875	0.6875	0.684

RANKING (IoU)

1. VGG cam_pro
2. VGG cam
3. MOBILENET cam
4. MOBILENET cam_pro

5. EFFICIENTNET cam_pro
6. RESNET18 cam_pro
7. RESNET18 cam
8. EFFICIENTNET cam

DESARROLLO – Contraste y Análisis de los Resultados

ANÁLISIS DEL MEJOR MODELO - Resultados

Clasificación (Recall)

1. VGG cam_pro
2. VGG cam
3. MOBILENET cam
4. MOBILENET cam_pro
5. RESNET18 cam_pro
6. RESNET18 cam
7. EFFICIENTNET cam_pro
8. EFFICIENTNET cam

Localización (IoU)

1. VGG cam_pro
2. VGG cam
3. MOBILENET cam
4. MOBILENET cam_pro
5. EFFICIENTNET cam_pro
6. RESNET18 cam_pro
7. RESNET18 cam
8. EFFICIENTNET cam

DESARROLLO – Contraste y Análisis de los Resultados

ANÁLISIS DE LA MEJOR TÉCNICA

	VGG				RESNET18				MOBILENET				EFFICIENTNET			
	cam		cam_pro		cam		cam_pro		cam		cam_pro		cam		cam_pro	
	C	GC	GC++	SGC++	C	GC	GC++	SGC++	C	GC	GC++	SGC++	C	GC	GC++	SGC++
Umbral	0.2	0.2	0.2	0.225	0.275	0.3	0.3	0.25	0.25	0.275	0.275	0.275	0.	0.15	0.15	0.15
IoU	0.5837	0.6054	0.6023	0.6093	0.4902	0.5121	0.5121	0.4391	0.528	0.5259	0.5259	0.4732	0.3733	0.5207	0.5207	0.5203
Recall	0.8155	0.8536	0.8587	0.8501	0.7421	0.8189	0.8189	0.8151	0.8003	0.8388	0.8388	0.8208	1.	0.7838	0.7838	0.7788
Precision	0.6838	0.684	0.6747	0.6896	0.6004	0.5760	0.5760	0.4848	0.6205	0.5939	0.5939	0.5387	0.3733	0.6122	0.6122	0.6098
F1-Score	0.7439	0.7594	0.7557	0.7615	0.6638	0.6763	0.6763	0.6175	0.699	0.694	0.694	0.6487	0.5437	0.6875	0.6875	0.684

RANKING

1. Grad-CAM: desempeño muy bueno. Si no es el mejor en cada caso, está muy cerca de serlo. Bajo coste computacional.
2. Grad-CAM++: resultados similares a Grad-CAM pero con un ligero mayor coste computacional.
3. Smooth Grad-CAM++: gran coste computacional + variabilidad según el modelo



La técnica básica CAM no se tiene en cuenta porque se usan modelos distintos (restricción de arquitectura)

DESARROLLO – Contraste y Análisis de los Resultados


ANÁLISIS DEL MEJOR PAR *MODELO-TÉCNICA*

VGG16 cam_pro - Grad-CAM

PATHOLOGICAL



Grad-CAM



DESARROLLO – Contraste y Análisis de los Resultados

ANÁLISIS DEL MEJOR PAR *MODELO-TÉCNICA*

VGG16 cam_pro - Grad-CAM

CLASIFICACIÓN				LOCALIZACIÓN					
Accuracy	Recall	Precision	F1-Score	Umbral	IoU	IoU / IoU _{sup}	Recall	Precision	F1-Score
0.9912	0.98667	0.9939	0.9903	0.2	0.6054	0.724	0.8536	0.684	0.7594

Factores determinantes que impiden mejores resultados de localización

1. Error en el etiquetado de las máscaras.
2. Error acarreado de la redimensión del mapa de activación (IoU_{sup}).

CONCLUSIONES

CONCLUSIONES

1. Se han cumplido los objetivos del trabajo
2. Se ha encontrado un modelo lo suficientemente bueno para pasarlo con un médico
3. Se demuestra que se puede solucionar el problema de localización resolviendo un problema de clasificación, con lo que eso conlleva de tiempo de etiquetado..

TRABAJO FUTURO

1. Intentar arreglar las barreras de localización que nos hemos encontrado.
2. Posibilidad de validar este sistema en un entorno real
3. Intentar mejorar el desempeño de los modelos más pequeños para ahorrar costes

GRACIAS POR VUESTRO TIEMPO

FIN

de esta preciosa etapa



**UNIVERSIDAD
DE GRANADA**

BIBLIOGRAFÍA

1. B. Zhou, A. Khosla, A. Lapedriza, A. Oliva, and A. Torralba. Learning Deep Features for Discriminative Localization. CVPR'16 (arXiv:1512.04150, 2015).
2. Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-CAM, oct 2019. URL <https://doi.org/10.1007%2Fs11263-019-01228-7>
3. Aditya Chattopadhyay, Anirban Sarkar, Prantik Howlader, and Vineeth N Balasubramanian. Grad-CAM++: Generalized gradient-based visual explanations for deep convolutional networks. mar 2018.. URL <https://doi.org/10.1109%2Fwacv.2018.00097>.
4. Daniel Omeiza, Skyler Speakman, Celia Cintas, and Komminist Weldermariam. Smooth grad-cam++: An enhanced inference level visualization technique for deep convolutional neural network models, 2019. URL <https://arxiv.org/abs/1908.01224>.
5. Miguel Lopez-Perez Adrian Colomer Maria A. Sales Rafael Molina Angel E. Esteban and Valery Naranjo. SICAPv1 Biomedicine. <https://www.sciencedirect.com/science/article/pii/S0169260719303906?via%3Dihub>.